

基于 Truth Direction 的 GPT-2-small 事实判断机制定位与推理时干预研究

摘要

本项目围绕“大模型机制可解释性”课程要求，研究 GPT-2-small 在事实判断任务中是否存在可定位、可干预、可复现的 true/false 内部表征。我们构建了 528 条英文事实判断样本，覆盖 capital、continent、element_symbol、book_author、landmark_country、science、math 七个领域，并使用 TransformerLens 提取每层 residual stream 激活。实验包括三部分：第一，使用 linear probe、PCA 和 activation patching 定位事实真假信息所在层与模块；第二，使用 vector arithmetic、steering 和 ablation 在推理阶段干预模型内部表示；第三，对齐 truth direction / geometry of truth 相关论文，复现“真假表征在激活空间中呈线性结构”的核心思想，并分析其局限。

主要结果表明：在混合领域事实判断中，GPT-2-small 的通用 truth direction 较弱；但在结构一致的 capital fact verification 中，中后层 residual stream 出现强线性可分信号，最佳 AUC 为 0.953。Activation patching 显示，在 capital recall 任务中，最后层 residual stream patching 可以恢复目标首都 token 的 logit。Probe-direction steering 能稳定移动内部 probe score，但 naive global steering 没有提升 true/false 输出判断；单方向 ablation 能移除已发现方向上的 score gap，但重新训练 probe 仍能恢复高 AUC，提示真假信息存在冗余或分布式表示。

1. 研究问题与项目目标

本项目选择“事实判断”作为具体可解释性现象。给定一句陈述，例如：

The capital of France is Paris.

我们希望回答以下问题：

- GPT-2-small 的哪些层开始包含可线性读取的 true/false 信息？
- 这些信息主要体现在 residual stream、attention output 还是 MLP output 中？
- 从激活中学到的 truth direction 是否能在推理阶段改变模型内部表示或输出行为？
- 这种 truth/false 线性结构是否跨事实领域稳定？

课程要求中的三项任务对应如下：

课程要求	本项目实现
Locate	Linear probe、PCA、activation patching 定位关键层与模块
Steer & Improve	Probe-direction steering 与 probe-direction ablation
顶会/Arxiv 复现	对齐 truth direction / geometry of truth 工作，复现线性真假表征和因果干预思想

2. 相关工作与复现对象

本项目主要对齐两类近期机制可解释性工作。

第一类是 Marks and Tegmark 的 *The Geometry of Truth: Emergent Linear Structure in Large Language Model Representations of True/False Datasets*。该工作提出，LLM 对 true/false statements 的内部表示可能在线性结构，并通过 probe、可视化和因果干预论证 truth direction 的存在。

第二类是 Bao et al. 2025 年 arXiv 论文 *Probing the Geometry of Truth: Consistency and Generalization of Truth Directions in LLMs Across Logical Transformations and Question Answering Tasks*。该论文关注 truth direction 是否稳定、是否能被简单 probe 识别、以及是否能跨上下文或任务泛化。

本项目没有直接复现大模型上的全部设置，而是在 GPT-2-small 上做一个小规模、可复现、可视化充分的版本。复现点包括：

- 构建 true/false statement dataset;
- 对每层 residual stream 训练 linear probe;
- 用 PCA 辅助观察激活空间结构;
- 用 activation patching 和 steering/ablation 测试方向的因果作用;
- 通过分领域 sweep 检查 truth direction 是否跨领域稳定。

3. 数据集与实验设置

数据集位于：

data/facts.csv

数据规模为 528 条英文事实判断样本，true/false 完全平衡：

true = 264
false = 264

领域分布如下：

Domain	Rows
capital	152
continent	86
element_symbol	80
book_author	60
landmark_country	60
science	50
math	40

每个 pair_id 包含一条 true statement 和一条对应 false statement。实验使用 group split，避免同一个事实对同时出现在训练集和测试集中，从而降低数据泄漏。

模型和框架：

Model: gpt2-small
Framework: TransformerLens
Hook points: hook_resid_post, hook_attn_out, hook_mlp_out

主要 prompt 模板包括:

Statement: {statement}
The statement is

Statement: {statement}
Answer true or false:

Question: Is the following statement true or false?
{statement}
Answer:

主要指标:

- Accuracy: 固定阈值下的分类准确率;
- AUC: probe 对 true/false 样本的排序能力;
- Separability AUC: $\max(\text{AUC}, 1 - \text{AUC})$, 用于衡量可分性, 即使方向反了也能体现线性结构;
- Logit difference: 目标 token 与对照 token 的输出 logit 差;
- Recovery: activation patching 后目标 logit difference 的恢复比例。

4. Locate: 线性定位与可视化

4.1 分领域 probe sweep

我们首先对所有领域和 prompt 进行 sweep。结果显示, 混合领域的通用 truth direction 较弱, 而结构一致的 capital 领域最稳定。

Domain	Prompt	Best Layer	Accuracy	AUC	Separability AUC
capital	answer	8	0.826	0.953	0.953
capital	statement_is	6	0.804	0.940	0.940
capital	question	7	0.804	0.932	0.932
continent	statement_is	11	0.808	0.846	0.846
landmark_country	statement_is	9	0.778	0.815	0.815

结果文件:

figures/probe_sweep.csv
figures/probe_sweep_summary.png

这一结果说明, truth direction 不应被简单理解成一个跨所有事实领域共享的单一方向。至少在 GPT-2-small 上, 领域和 prompt 对真假可分性有很大影响。

4.2 Focused capital probe

由于 capital 领域最稳定, 我们使用如下 prompt 进行 focused probe:

Statement: {statement}
Answer true or false:

中后层结果最强:

Layer	Accuracy	AUC
5	0.848	0.941
6	0.826	0.943
7	0.848	0.938
8	0.826	0.953
9	0.804	0.941
10	0.870	0.947

最佳 AUC 出现在第 8 层，最佳 accuracy 出现在第 10 层。考虑 GPT-2-small 共 12 层，这说明 capital fact verification 的真假信息主要在中后层形成。

结果文件：

figures/probe_capital_answer.csv
figures/probe_capital_answer.png

4.3 PCA 辅助可视化

我们对第 8 层 capital residual activation 做 PCA 可视化：

figures/pca_capital_layer8.csv
figures/pca_capital_layer8.png

PCA 的 PC1 explained variance 为 0.620，PC2 explained variance 为 0.117。二维图没有清楚分开 true/false，这一点很重要：linear probe 的强 AUC

不一定对应解释方差最大的主成分。换句话说，真假可分性主要存在于 supervised high-dimensional probe direction 中，而不是无监督 PCA 的前两个方向中。

4.4 样本级错误分析

第 8 层 capital probe 在测试集上共有 46 条样本，其中 38 条预测正确，8 条预测错误，accuracy=0.826，AUC=0.953。

代表性错误如下：

Statement	Label	Prediction	prob_true
The capital of Laos is Vientiane.	true	false	0.003
The capital of Canada is Amman.	false	true	0.964
The capital of Chile is Santiago.	true	false	0.179
The capital of India is New Delhi.	true	false	0.217
The capital of Morocco is Rabat.	true	false	0.219

Statement	Label	Prediction	prob_true
The capital of Nigeria is Mexico City.	false	true	0.688

结果文件：

figures/error_analysis_capital_layer8.csv
figures/error_analysis_capital_layer8_errors.csv

这个结果说明：probe 的排序能力很强，因此 AUC 很高；但固定 0.5 阈值仍会产生错误。也就是说，当前实验更能证明“该层存在可线性读取的真假信息”，而不是证明该 probe 本身已经是完美事实判断器。

5. Activation Patching: 因果定位

为了获得比 probe 更强的因果证据，我们构造 capital recall 任务：

clean: The capital of France is
corrupt: The capital of Germany is
metric: $\text{logit}(\text{"Paris"}) - \text{logit}(\text{"Berlin"})$

在 corrupt prompt 的前向传播中，将 clean prompt 在某层最后 token 位置的 activation patch 进去，观察目标 logit difference 是否恢复。实验比较三类 hook：

blocks.{layer}.hook_resid_post
blocks.{layer}.hook_attn_out
blocks.{layer}.hook_mlp_out

模块级最好结果如下：

Component	Best Layer	Patched Logit Diff	Mean Recovery	Median Recovery
resid_post	11	0.264	1.000	1.000
attn_out	11	-0.672	1.762	1.077
mlp_out	7	-1.022	0.388	0.074

结果文件：

figures/activation_patching_capital_recall.csv
figures/activation_patching_capital_recall.png

最后层 residual stream patching 可以把平均 logit difference 恢复到 clean baseline，说明后层 residual stream 携带了足以恢复目标首都 token 的信息。attn_out 在第 11 层的 mean recovery 很高，但 patched logit diff 仍未翻正，因此更适合解释为“对恢复有强贡献”，而不是“单独足以完成恢复”。mlp_out 单独 patching 效果较弱。

6. Steer & Improve: 推理阶段干预

6.1 Probe-direction steering

我们在第 8 层 capital activation 上训练 logistic probe，并将 probe 权重方向转换回原始 residual stream 坐标，得到单位方向 v_{probe} 。随后在推理时执行：

$$h = h + \alpha * v_{\text{probe}}$$

alpha sweep 结果如下：

Alpha	Logit-sign Accuracy	Probe-threshold Accuracy	Mean Probe Score
-8	0.500	0.500	-9.353
-4	0.500	0.500	-5.353
-2	0.500	0.500	-3.353
-1	0.500	0.507	-2.353
0	0.500	1.000	-1.353
1	0.500	0.500	-0.353
2	0.500	0.500	0.647
4	0.500	0.500	2.647
8	0.500	0.500	6.647

结果文件：

figures/steering_capital_probe_layer8.csv
figures/steering_capital_probe_layer8.png
figures/steering_capital_probe_layer8_accuracy.png
figures/steering_capital_probe_layer8_probe_accuracy.png

这个结果说明，steering 可以稳定控制内部 probe score，且 alpha 每增加 1，mean probe score 近似增加 1。但 naive global steering 对所有样本加入同一方向，true 和 false 样本会一起移动，因此没有提升输出层 true/false logit-sign accuracy。这是一个重要负结果：可读性不等于直接可控性。

6.2 Probe-direction ablation

为了进一步检验该方向是否承载可读信息，我们从 residual activation 中移除 probe direction 上的投影：

$$h_{\text{abladed}} = h - \text{strength} * (h \cdot v_{\text{probe}}) * v_{\text{probe}}$$

结果如下：

Strength	Fixed Direction Score Gap	Fixed Direction Accuracy	Retrained Probe AUC
0.00	0.573	0.826	0.953
0.25	0.430	0.500	0.955
0.50	0.286	0.500	0.958
0.75	0.143	0.500	0.951
1.00	-0.000	0.500	0.945
1.25	-0.143	0.500	0.953
1.50	-0.286	0.478	0.962

结果文件：

figures/ablation_capital_probe_layer8.csv
figures/ablation_capital_probe_layer8.png
figures/ablation_capital_probe_layer8_score_gap.png

单方向 ablation 能将原 probe direction 上的 score gap 从 0.573 降到约 0，这说明该方向确实承载可读的 true/false 信息。然而，在 ablated activations 上重新训练 probe 后，AUC 仍保持在 0.94 以上。这提示 capital truth/false 信息并不只存在于单一方向中，而可能分布在多个相关方向或子空间中。

7. 论文复现与拓展总结

本项目复现了 truth direction / geometry of truth 相关工作的几个核心思想：

论文思想	本项目复现
True/false statement datasets	构建 528 条英文事实判断样本
Linear truth representation	每层 residual stream linear probe
Layer localization	分领域 sweep 和 focused capital probe
Visualization	PCA 激活空间可视化
Causal intervention	Activation patching、steering、ablation
Generalization analysis	比较不同领域和 prompt 的可分性

本项目的拓展主要在于：没有只报告成功结果，而是明确分析了三个负结果或局限。

第一，混合领域 truth direction 明显弱于 capital 单领域，说明 truth direction 的泛化并不自动成立。

第二，PCA 二维投影不能清楚分离 true/false，说明无监督高方差方向不一定等于可解释的 truth direction。

第三，steering 可以移动内部 probe score，但不能直接改善输出判断，说明“probe 可读”与“模型实际用于输出的因果机制”之间仍有距离。

8. 个人分析与局限

这组实验最重要的启发是：机制可解释性中的“现象定义”非常关键。如果把任务定义为“所有事实判断”，GPT-2-small 的通用 truth direction 并不强；但如果把任务收窄到结构一致的 capital fact verification，中后层 residual stream 中会出现很强的线性可分结构。这说明可解释性实验不能只问“模型有没有某个抽象概念”，还要问该概念在什么数据分布、prompt、层和模块中稳定出现。

另一个重要启发是：linear probe 的成功不能直接等价于因果解释。第 8 层 probe AUC 达到 0.953，但 naive steering 没有提升输出行为；单方向 ablation 移除一个 direction 后，重新训练 probe 仍然能恢复高 AUC。这说明模型内部信息可能是冗余和分布式的，单一方向只能解释其中一部分结构。

当前局限包括：

- 模型只使用 GPT-2-small，尚未扩展到 Qwen2.5-0.5B 或 Qwen2.5-1.5B。
- Activation patching 主要是 layer/module 级，还没有做 attention head 级 patching。
- Steering 使用全局固定方向，没有做输入条件化 steering。
- 数据集是人工构造的小规模事实判断集，虽然便于可复现，但覆盖面有限。

9. 结论

本项目完成了一个围绕事实判断的机制可解释性小闭环：先用 linear probe 定位 truth/false 信息，再用 PCA 和错误分析理解其表现，随后用 activation patching、steering 和 ablation 检验其因果与可控性。

结论可以概括为：

- GPT-2-small 在结构一致的 capital fact verification 中存在强线性 truth/false 表征，最佳 AUC 为 0.953。
- 该表征主要出现在中后层 residual stream 中。
- Capital recall 的 activation patching 提供了更直接的因果证据，最后层 residual stream patching 可以恢复目标首都 logit。
- Probe direction 可以被 vector arithmetic 控制，但 naive global steering 不能直接 improve 输出判断。
- Truth/false 信息不是单一方向独占的，单方向 ablation 后仍可被重新训练 probe 读出，说明存在冗余子空间。


因此，本项目支持一个更谨慎的观点：truth direction 在特定结构化任务中确实可以被定位和干预，但它不是跨所有事实领域无条件稳定的单一按钮。机制可解释性实验需要同时报告成功定位、失败案例和负结果，才能避免把 probe 可读性过度解释为完整因果机制。

参考文献

- Samuel Marks and Max Tegmark. *The Geometry of Truth: Emergent Linear Structure in Large Language Model Representations of True/False Datasets*. arXiv:2310.06824.
<https://arxiv.org/abs/2310.06824>
- Yuntai Bao, Xuhong Zhang, Tianyu Du, Xinkui Zhao, Zhengwen Feng, Hao Peng, Jianwei Yin. *Probing the Geometry of Truth: Consistency and Generalization of Truth Directions in LLMs Across Logical Transformations and Question Answering Tasks*. arXiv:2506.00823.
<https://arxiv.org/abs/2506.00823>
- Leonard Bereska and Efstratios Gavves. *Mechanistic Interpretability for AI Safety -- A Review*. arXiv:2404.14082.
- *Locate, Steer, and Improve: A Practical Survey of Actionable Mechanistic Interpretability in LLMs*. arXiv 2026.


附录：关键可视化结果

分领域 probe sweep




figures/probe_sweep_summary.png

Capital probe layer curve




figures/probe_capital_answer.png

Layer 8 activation PCA




figures/pca_capital_layer8.png

Activation patching recovery




figures/activation_patching_capital_recall.png

Probe-direction steering



figures/steering_capital_probe_layer8_probe_accuracy.png

Probe-direction ablation



figures/ablation_capital_probe_layer8_score_gap.png